

Convolución de imágenes en CPU y CUDA C

Práctica de laboratorio 01 – Computación Paralela

Michael Lata · Jordi Romero · Andres Morocho
Docente: Ing. Gabriel Leon

¿Qué hicimos?

- Tres filtros: media, nitidez y laplaciano
- Versiones secuencial (C/C++) y CUDA C
- Imágenes en escala de grises

2000 · 4000 · 6000

Resoluciónes evaluadas

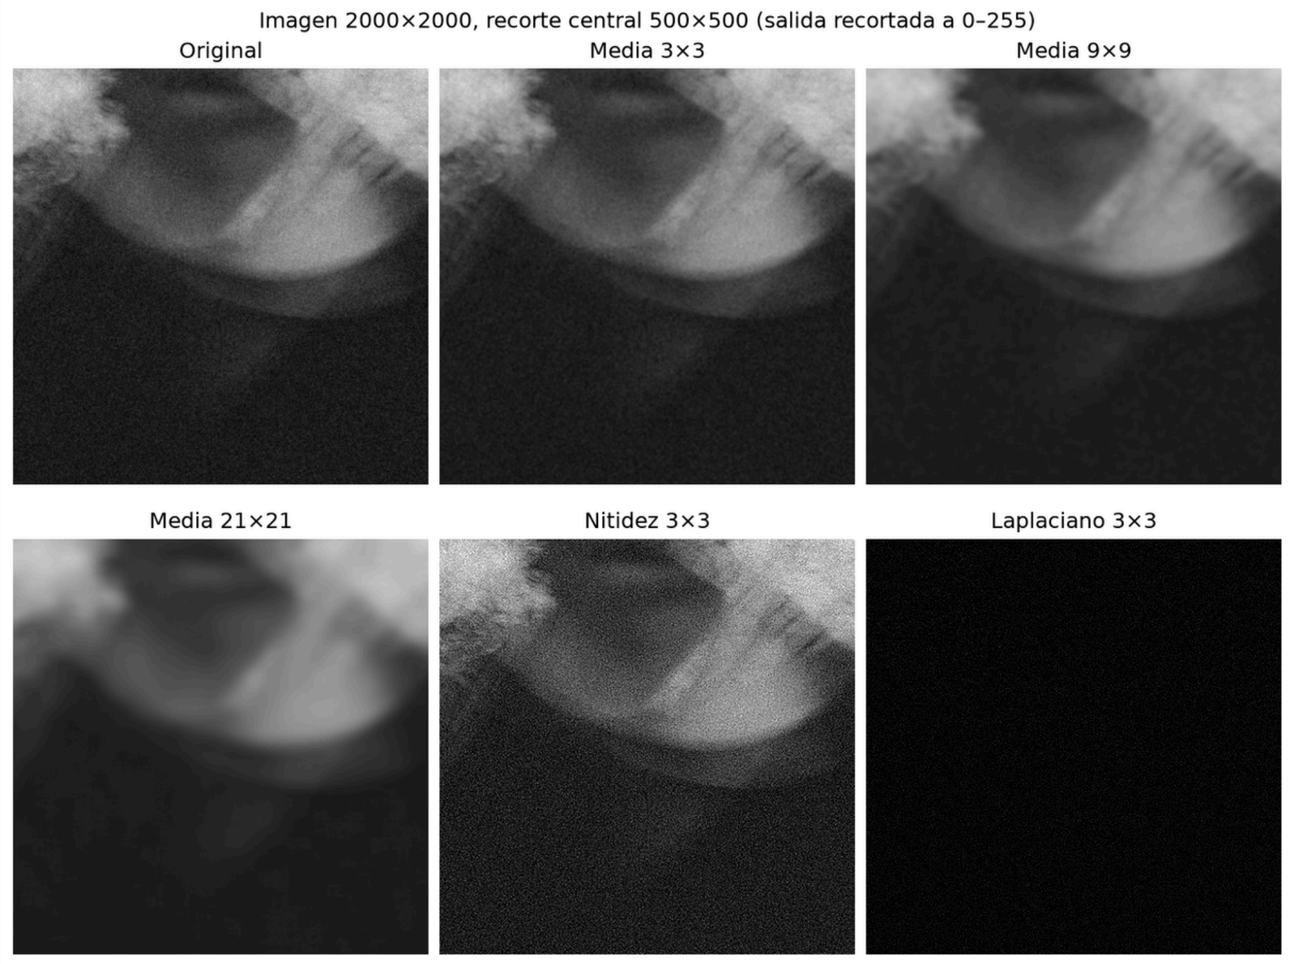
1001×777

Imagen de validación

Medir impacto de resolución, máscara, hilos y copias CPU–GPU

Filtros y máscaras

- Media k×k (k=3,9,21): todos los coeficientes valen $1/k^2$. Suaviza.
- Nitidez 3×3: [0 −1 0; −1 5 −1; 0 −1 0]. Realza bordes.
- Laplaciano 3×3: [0 1 0; 1 −4 1; 0 1 0]. Marca cambios de intensidad.
- Condiciones comunes: cálculo en float, extensión con ceros, entrada y salida separadas.



Distribución del trabajo en la GPU

```
tid = blockIdx.x · blockDim.x + threadIdx.x
fila = tid / ancho
columna = tid % ancho
```

3039

bloques para 1001×777 con 256 hilos; últimos 207 inactivos

- Un hilo calcula un píxel de salida
- bloques = (n + hilos − 1) / hilos
- Control de límite: tid < n

Datos y equipo

6200×8272 → 6200×6200 → 6000 · 4000 · 2000



- Las tres resoluciones salen de la misma foto y no se amplía ninguna
- CPU y GPU leen exactamente los mismos archivos.
- **Equipo**
  - Intel Core i7-13650HX (14 núcleos, 20 hilos) y 15 GiB de RAM.
  - RTX 4060 Laptop con 8 GB, capacidad de cómputo 8.9 y máximo de 1024 hilos por bloque.
  - CUDA 13.4

Validación

78 · 87 · 195

Prueba manual 5×5: CPU y GPU

1.22×10^{-4}

Error máximo en media

0.001

Tolerancia; 500 veces menor que 0.5

- Imagen 1001×777 prueba el último bloque
- Error 0 en nitidez y laplaciano
- CPU y GPU coinciden dentro de tolerancia

Cómo medimos

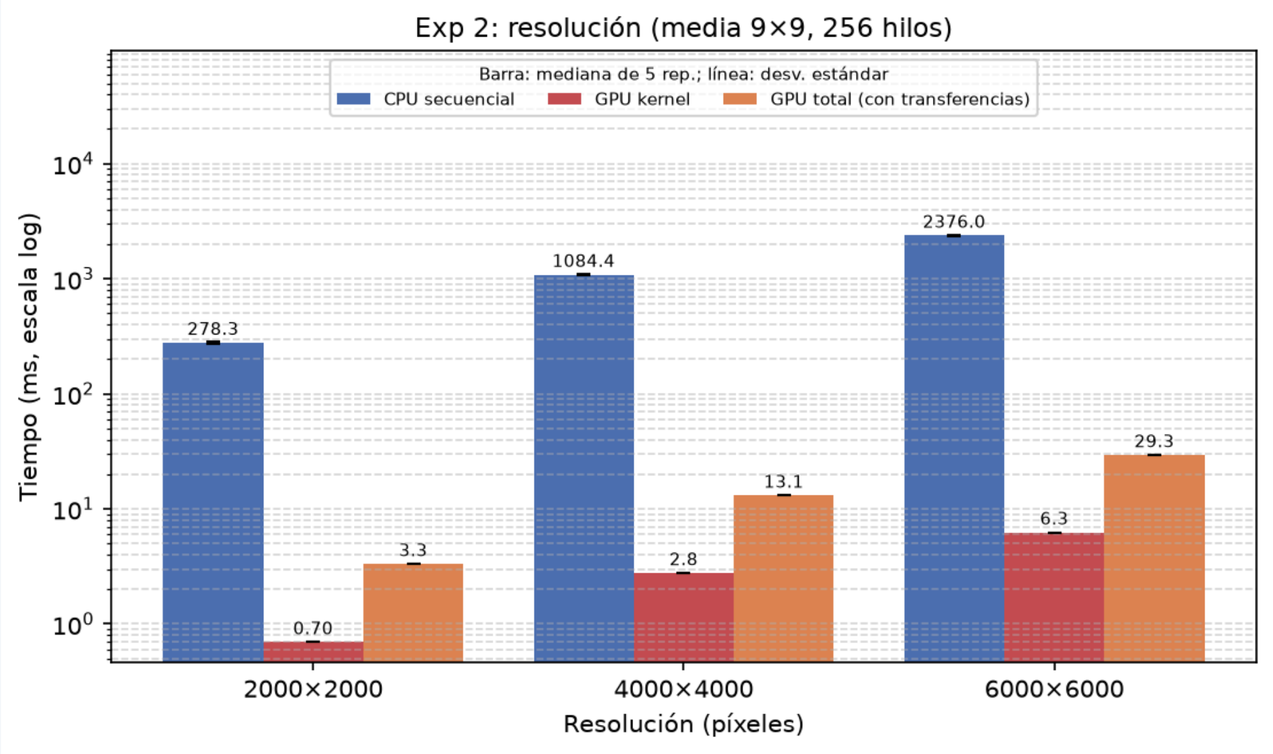
- 4 experimentos: filtro, resolución, máscara, hilos (128, 256, 512)
- Calentamiento y 5 repeticiones: mediana y desviación estándar
- Eventos CUDA: CPU→GPU, kernel y GPU→CPU
- GPU calentada 2 s; sin calentamiento varió hasta 8×
- kernel 9×9: 34.4 ms → 2.78 ms tras calentar

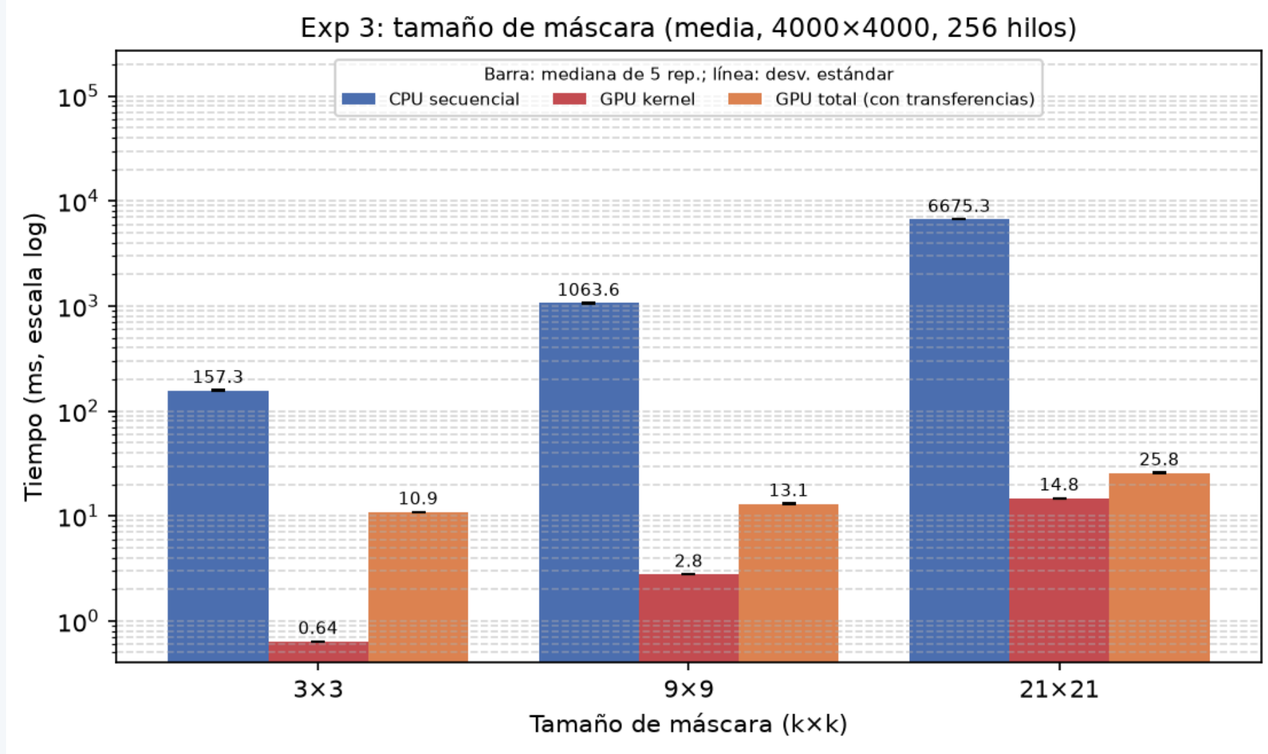
<0.5 %

Variación con calentamiento

Resolución y tamaño de máscara

- CPU: 2000→6000, 278 ms → 2376 ms
- GPU kernel: 0.70 → 2.77 → 6.25 ms
- 3×3 → 9×9: 9× trabajo, kernel 4.4× más
- Con 3×3, límite parece memoria





¿Cuánto tiempo se va en copias?

94 %

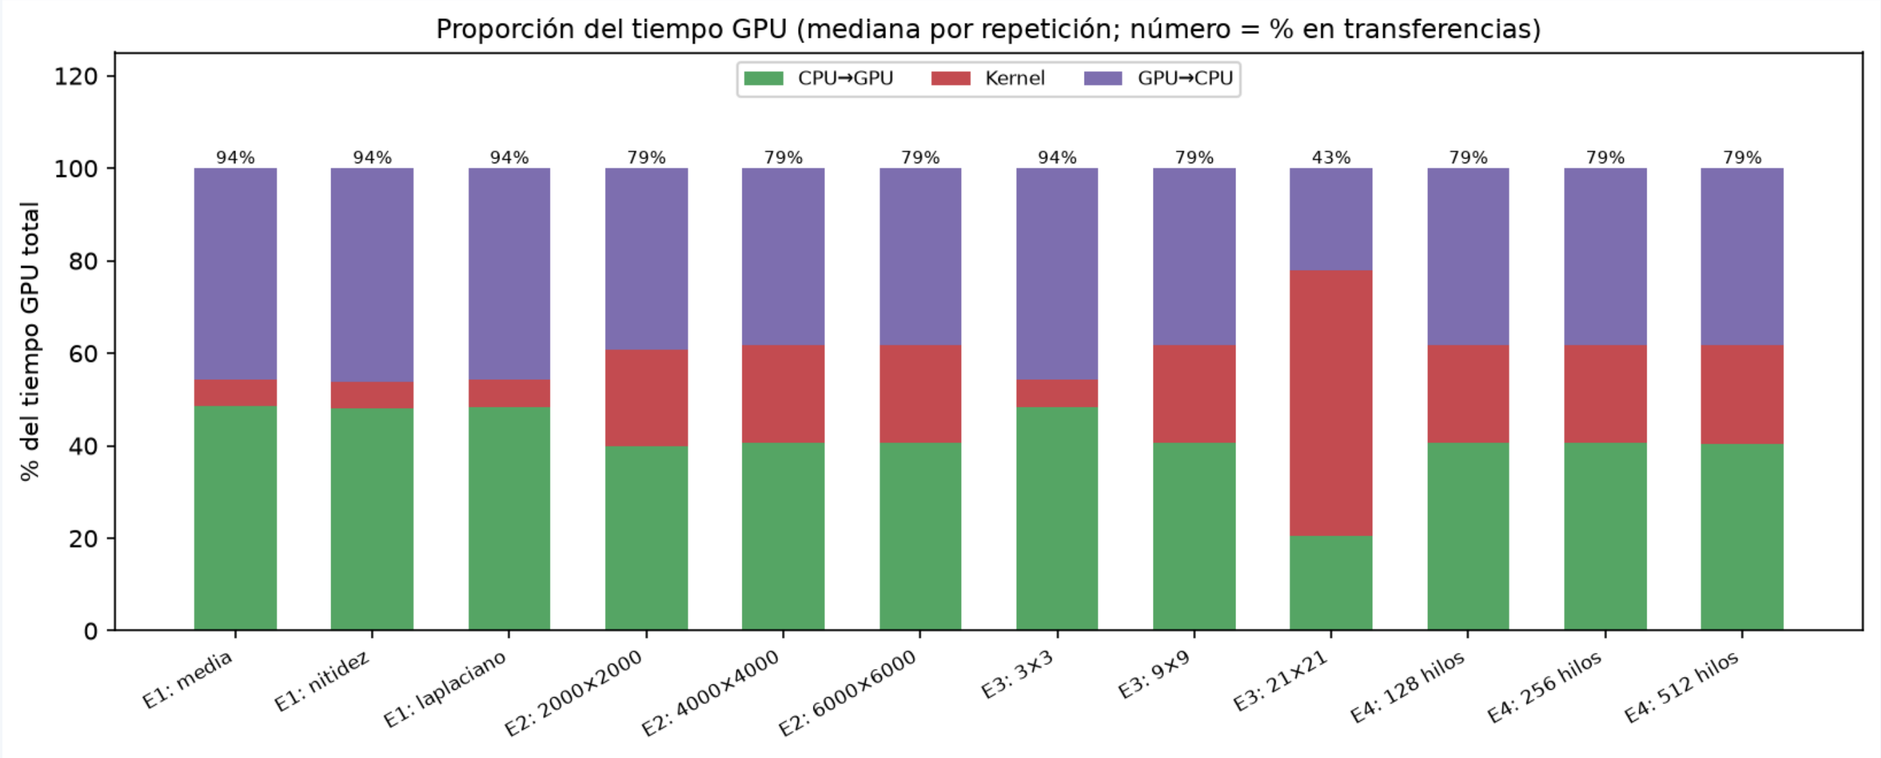
Máscara 3×3

79 %

Máscara 9×9

≈43 %

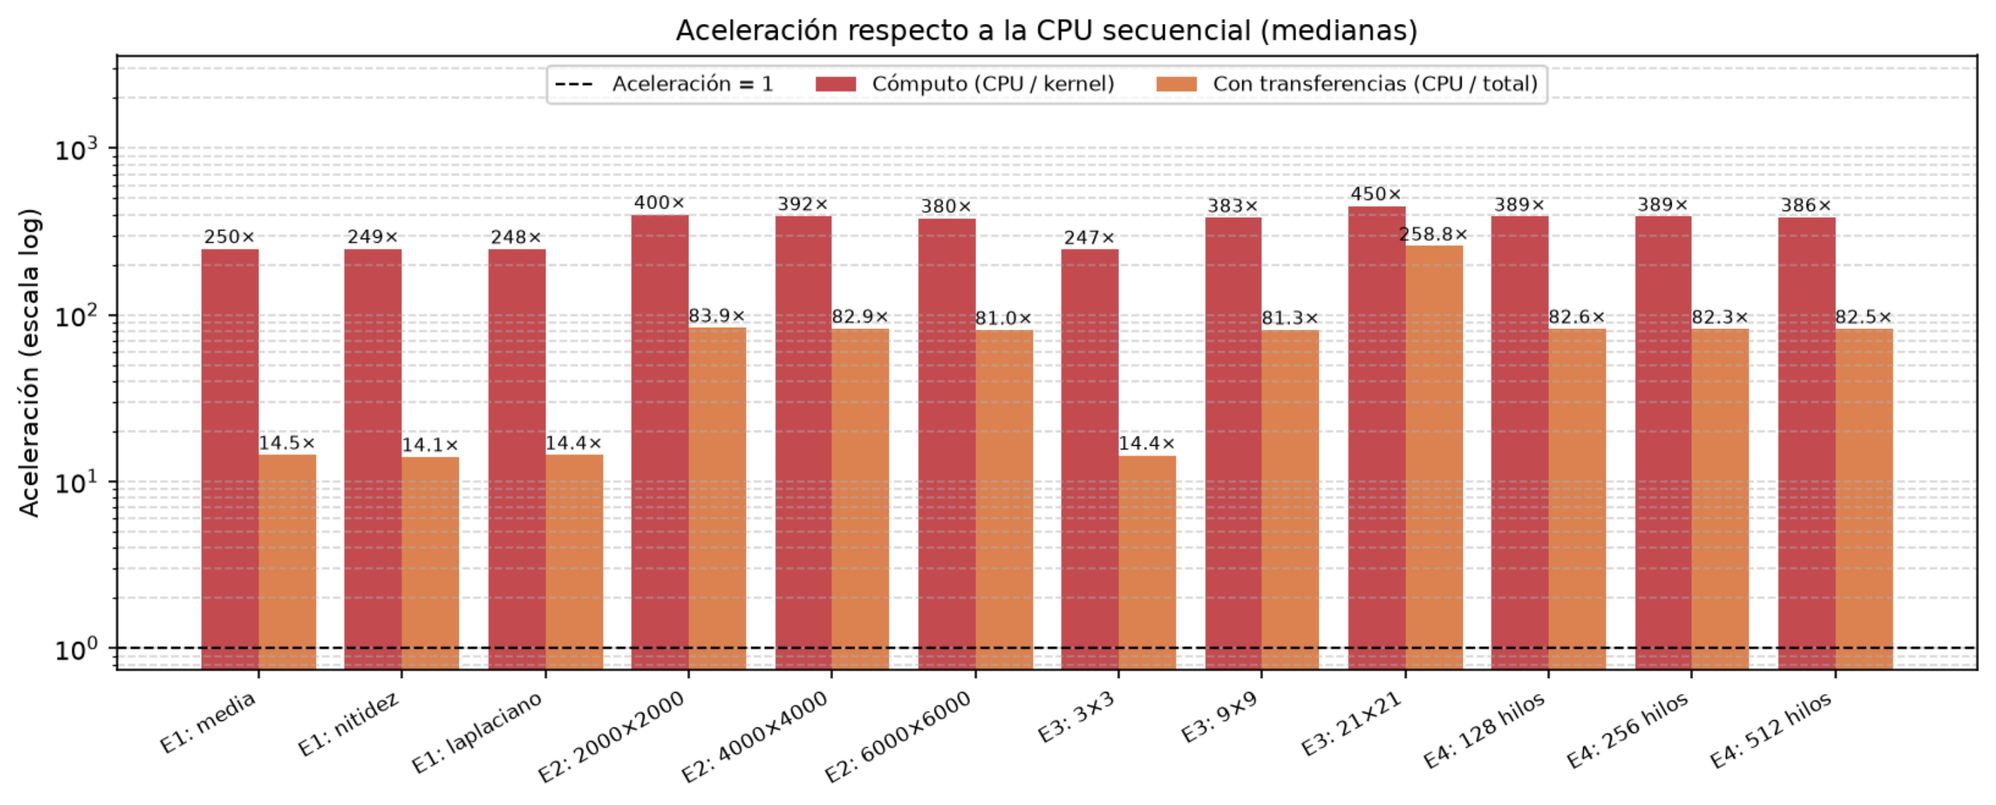
Máscara 21×21



La copia tarda lo mismo (~10 ms en 4000×4000); lo que cambia es el kernel

Aceleración

- Solo cómputo: ~250× (3×3) · 380-400× (9×9) · 450× (21×21)
- Con copias: 14× (3×3) · ~82× (9×9) · 259× (21×21)
- La ganancia real depende del trabajo por píxel

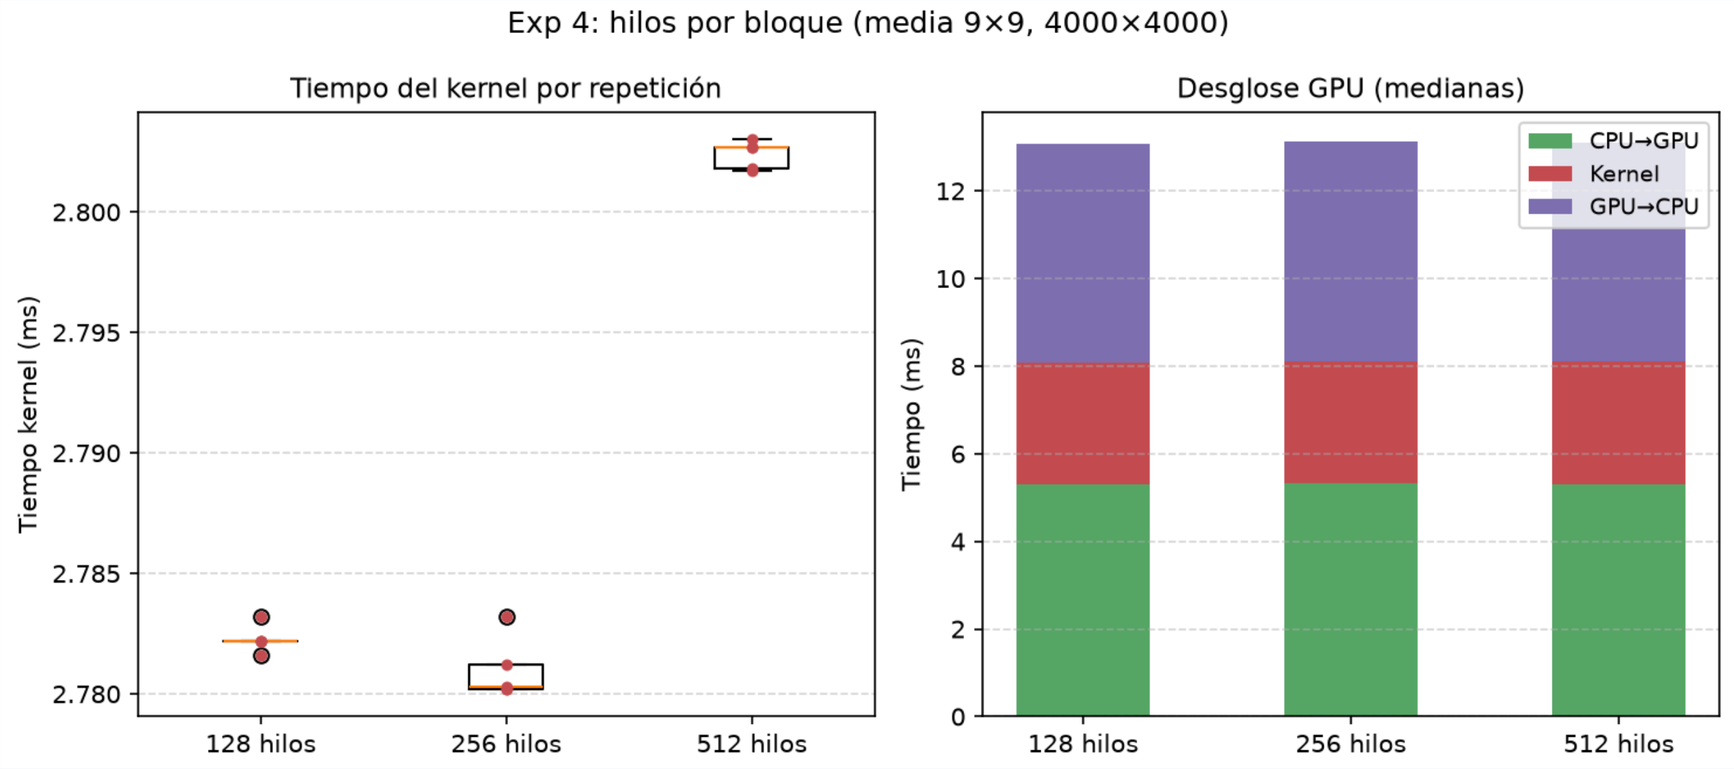


Hilos por bloque

0.8 %

512 es más lento (~22 µs)

- 128 y 256 hilos empatan
- Variación entre repeticiones <0.05 %
- En tiempo total no se nota: dominan las copias



Limitaciones

Un solo equipo portátil

Frecuencias GPU no fijadas

CPU secuencial: un núcleo vs toda GPU

Kernel básico en memoria global

Memoria del host paginable

Conclusiones

CPU y GPU entregan el mismo resultado

- Error $\leq 1.22 \times 10^{-4}$
- El tiempo crece con resolución y máscara
- Con máscaras pequeñas, las copias consumen casi toda la ganancia
- Los hilos por bloque casi no influyen
- En GPU portátil, hay que calentar antes de medir